

个人简历

基本信息

姓名：乐林风
年龄：23
籍贯：重庆市忠县
电话：13668456118
邮箱：2021214376@stu.cqupt.edu.cn



教育经历

2021.09 至 2025.06 重庆邮电大学 (本科) 软件工程
2025.09 至 2028.06 电子科技大学 (硕士) 软件工程

技能证书：CET-6, 全国大学生数学竞赛省一等奖、2026 华为软件精英挑战赛三等奖、2026 百度 CTI 决赛优秀奖

实习经历

2026.06 至今 openmvg (CFM 推理链路) 算法工程师

- **技术栈**：C++/CUDA, TensorRT, CUDA Streams & Events, 多流异步调度, 有界并发/背压, Nsight Systems, Python
- **实习概述**：负责三维重建产品线中局部特征（检测/描述/匹配）推理链路的部署与框架调度优化。主导设计并实现约 1.8 万行 C++ 推理运行时与调度层（含自研 CUDA kernel），将依赖外部进程的匹配链路改造为进程内 TensorRT 常驻推理 + 细粒度异步流水，并围绕端到端时延、峰值显存、数值一致性建立 profiling → 归因 → 门禁的完整闭环。
- **调度重构与计算/CPU overlap 掩盖（端到端 -44%，1.79×）**：将特征提取与匹配的依赖粒度从“阶段级”细化到“view 级”，用 CUDA Event 在 GPU 侧建跨流依赖、不阻塞 CPU 主线程，把下游阶段掩盖进关键路径；Phase1 内部再拆 2 条 stream 以 event DAG 串联。同场景「纯串行 vs 优化」受控 A/B 端到端 -44.2% (1.79×)，双侧各 3 次冷启动 CV<0.5%。机制与 LLM PD (prefill/decode) 阶段流水掩盖同构。
- **收益归因，排除并发调参（overlap 单独贡献 -22%）**：以三重独立证据闭环——① 扫描预取深度/worker 数，多配置墙钟差 <1%，证明收益对并发度不敏感；② 优化后各算子 device time 累计和未减反增、而端到端墙钟显著下降，该背离唯一解释是原本串行的 GPU 区间被重叠压缩；③ Matcher 流空泡指标同步收缩。大规模场景端到端 -22.1%。
- **有界显存资源池与水位背压（峰值显存 -55.8%）**：设计三层背压——host 有界预取队列 + GPU 常驻集高低水位迟滞准入 + 看门狗 fail-closed，将峰值显存 33.6GB → 14.9GB、约束进 20GB 软件门，使原本会 OOM 的负载可在 24GB 显存预算内运行。范式与 Continuous Batching 的有界 KV 池准入 + 排队、PagedAttention 的分页池一致。

2026.07-2026.08 loma.cpp Transformer 推理引擎 开发者

- **技术栈**：C++17 / CUDA / CUTLASS / FlashAttention v2 / CUB / TensorRT / LibTorch / Nsight
- **概述**：为 Ada 架构 2048-token Transformer 构建多精度、架构感知可路由的低延迟 C++/CUDA 推理引擎；参与 FP8 算子链路（FA2 FP8 内核 / Epilogue 融合 / PTQ 校准）。核心 Matcher 较 PyTorch(eager) 加速约 18 倍（37.3→2.0ms），同精度工程优化贡献约 4 倍。
- **FP8 Attention 内核**：基于 FA2 实现 SM89 专用 E4M3 内核（QK/PV 走 FP8 MMA、Softmax 保 FP32 归约），设为 Ada 默认路由；仅替换 Attention 路径即降端到端延迟 14.5%，512-token FMHA 微基准较 TensorRT-LLM 快 36%。
- **跨层 FP8 数据流**：用 CUTLASS 自定义 Epilogue 将残差累加与 E4M3 量化融入 GEMM 写回、直接产出下层 FP8 输入，消除 32 次冗余 Kernel Launch（18 拼接 + 14 量化），Matcher GPU 计算进入 sub-2ms。
- **Token 剪枝与量化校准**：CUB Block-Radix 运行时 Top-K 剪枝（2048→512，后段序列压至 1/4）+ 两阶段 PTQ 校准（AbsMax + 8192-bin 直方图 P99.99）；剪枝与 FP8 量化相对基线 AUC 差异均 <1pp。
- **多精度路由与可复现部署**：YAML 路由注册表按架构自动 Dispatch（SM89→FP8+FA2，SM80/SM90→BF16）；内容寻址 TensorRT 引擎缓存（指纹绑定契约/架构/版本/源 SHA + 逐引擎校验）保证跨环境可复现。

专业技能

- **编程与体系结构**：熟练 C++/CUDA/Python，熟悉 GPU 编程与 CPU/GPU 体系架构；掌握 TensorRT 推理框架、Nsight 性能剖析与内核级性能调优。
- **推理优化方法论**：擅长算子/访存/并发瓶颈定位与 overlap 掩盖，先量化关键路径与理论上界再动手；了解 LLM 推理（PD/AF 分离、KV Cache）与分布式并行/通算融合方向，持续深入中。